ИТМО

Применение различных методов параметрически-эффективной тонкой настройки для адаптации языковых моделей для вопросно-ответных систем в предметной области на основе Compute-efficient Retrieval Augmented Fine-Tuning

Магистерская диссертация
Студент: Протасов Т.М., M4238
Руководитель ВКР: Аксенов В.Е., доцент, к. т. н.
Соруководитель ВКР: Мосягин И.Ю., преподаватель.

Контекст

LLM (Large Language Model) показывают высокое качество в задачах **QA** (question answering), но:

- плохо работают в *узких доменах*
- не знают *специфические знания*

Причина:

- *pretraining* не покрывает доменную специфику

Существующие решения

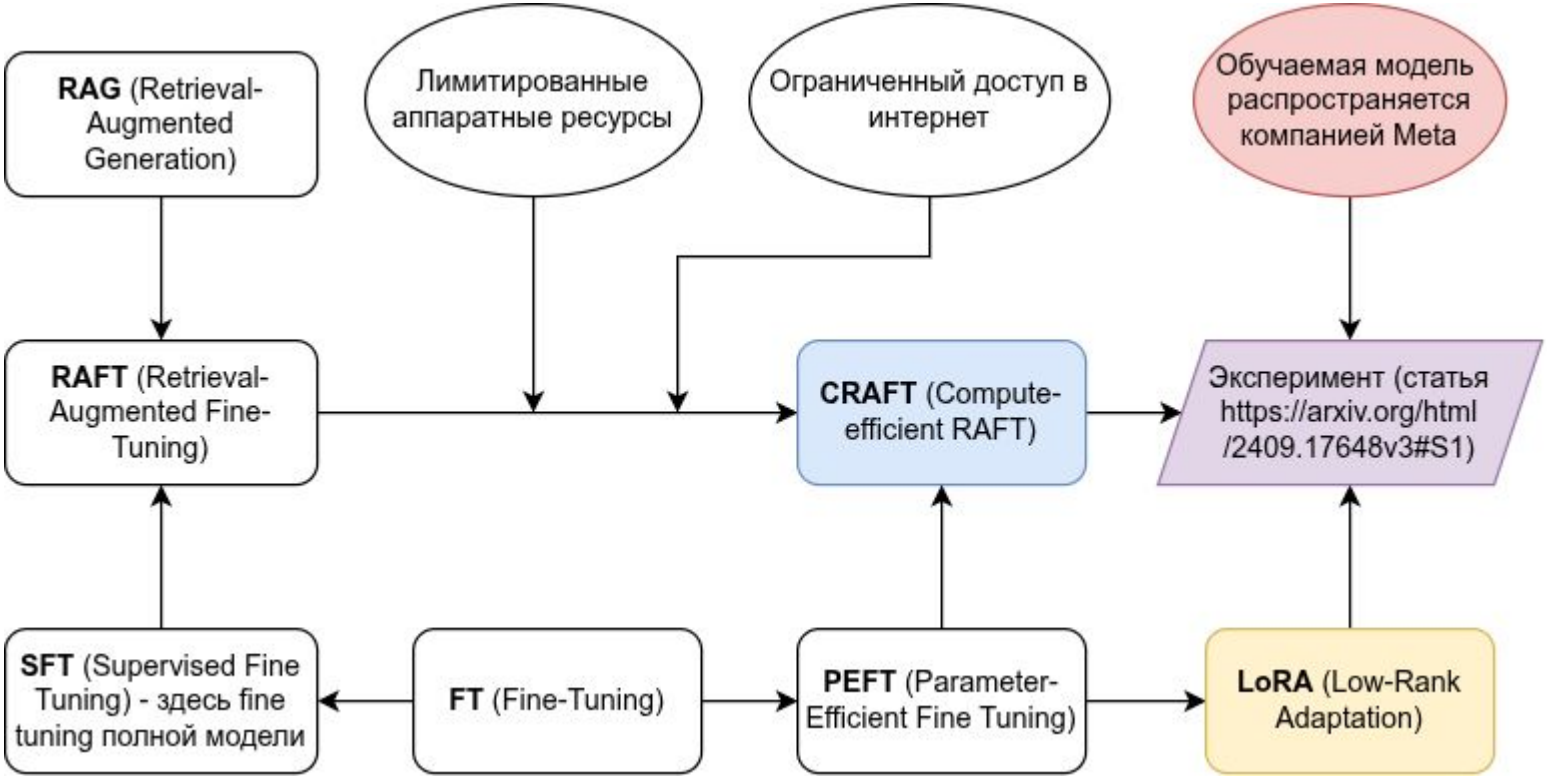

Meta Platforms Inc. признана экстремистской организацией и запрещена на территории Российской Федерации

Проблема

Ключевая проблема - отсутствие знаний об оптимальности методов PEFT применительно к области RAFT:

- Качество
- Устойчивость к шуму
- Ресурсы
- Время обучения

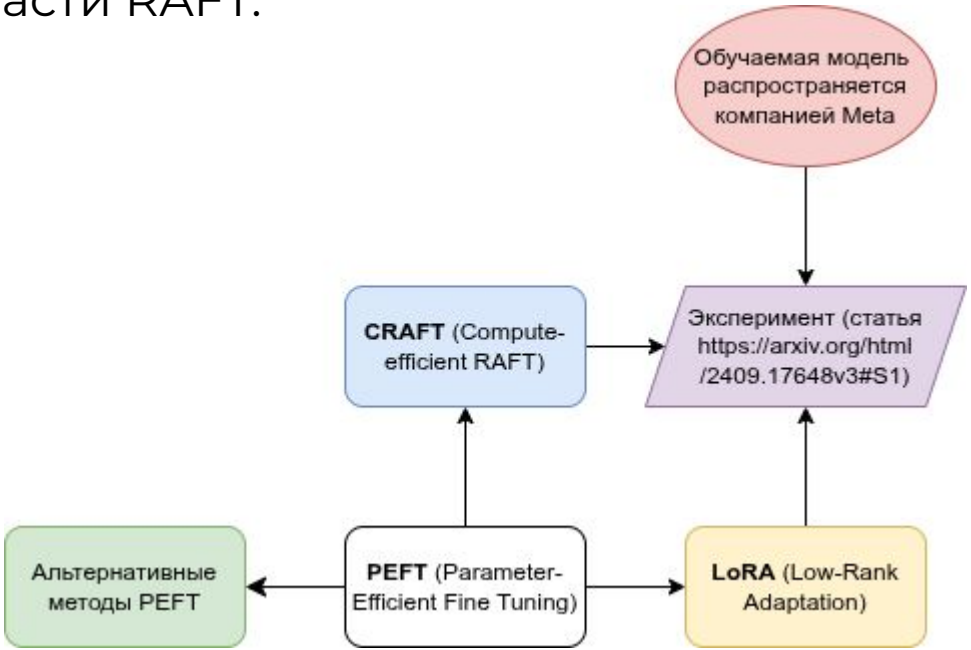

Цели и задачи исследования

Целью ВКР является исследование влияния различных методов PEFT на эффективность RAFT QA-систем.

Задачи:

- реализовать CRAFT pipeline
- применить разные PEFT методы
- провести сравнительный анализ
- выявить оптимальные методы в различных условиях относительно заранее определённых метрик

Решение задач

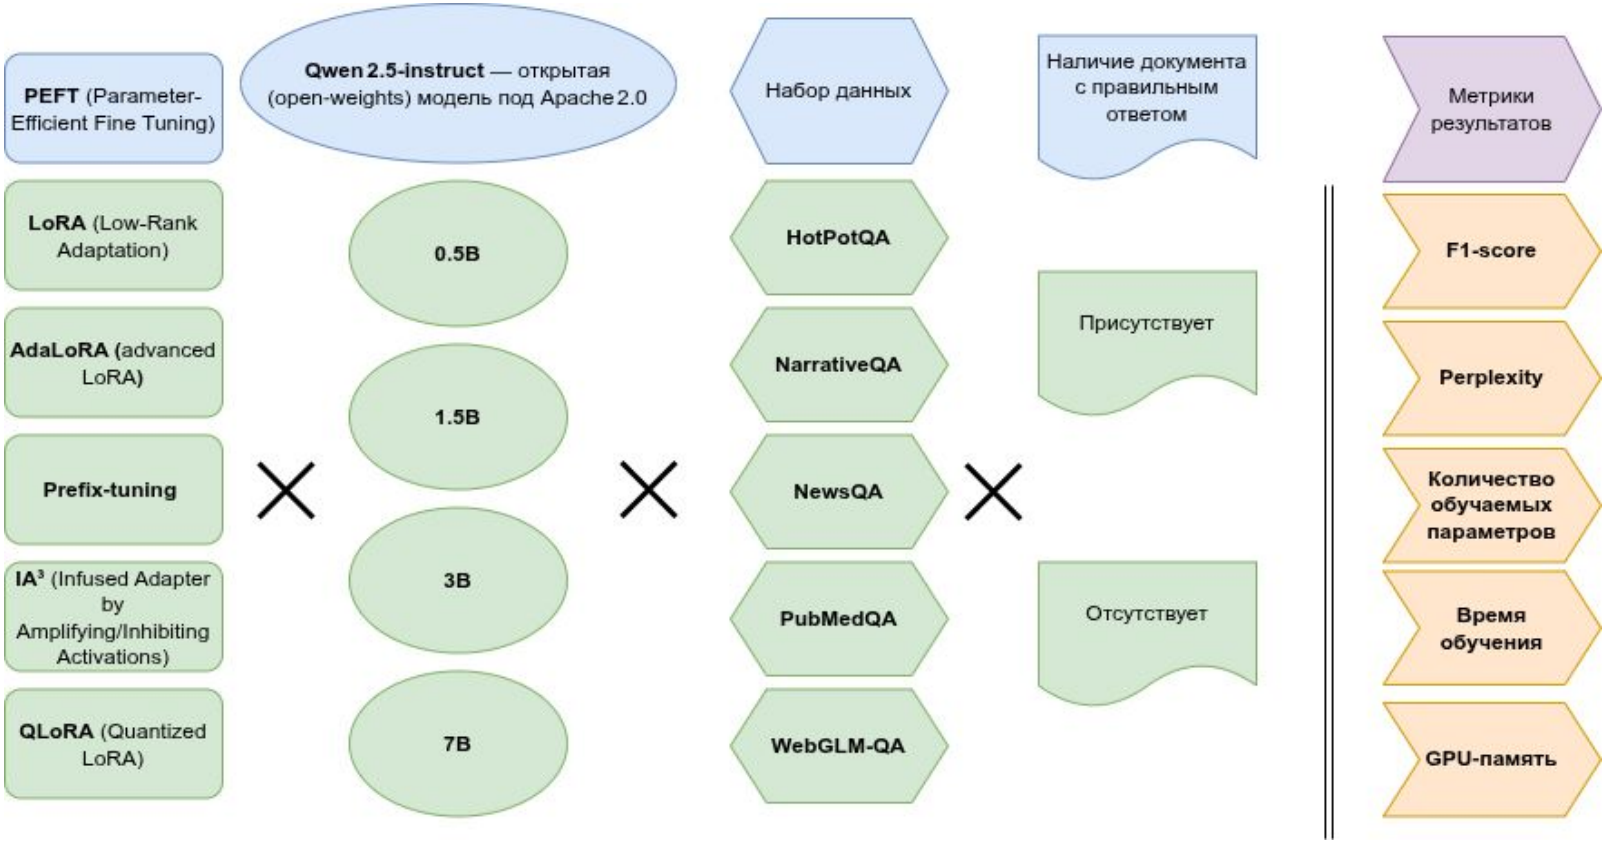

Полученные результаты

Полученные результаты

Полученные результаты

Выводы

Доделать

- Поставить эксперимент
- Описать полученные результаты
- Написать вывод